

Shot3R: 基于对齐与递归状态传播解耦的多镜头视频流式多人体四维重建

Anonymous authors

Paper under double-blind review



Figure 1: Shot3R 将依次到达的单目镜头流式重建到统一世界坐标系中，同时维持相机、人体运动和人物身份的连续性。角度表示相对于第一镜头的源相机旋转。

Abstract

从一段由多个镜头组成的单目视频中，在统一世界坐标系下重建人体运动是一项具有挑战性的任务，因为突然发生的镜头切换会带来大幅视角变化，并显著改变画面中的可见场景和人体外观。现有在线方法通常假设输入在时间上连续；已有多镜头方法则联合处理镜头或优化已观测序列，而不是在帧到达时递归地产生预测。在镜头切换处，递归历史为恢复镜头间世界坐标关系提供参照，但将同一状态继续传播到新镜头可能引起随时间变化的相机漂移，而单独重新初始化又会丢失这一参照。为处理这一冲突，我们提出 Shot3R，一个通过解耦镜头间对齐与递归状态传播，实现多镜头视频流式多人体四维重建的在线框架。在每个镜头边界，历史条件路径估计镜头间变换，独立重新初始化的路径则提供新镜头中继续传播的状态。随后，基于几何的关联建立跨镜头身份对应，共享变换将相机和人体配准到已有世界坐标系。在三个多人体基准上，相比跨镜头直接延续递归状态，Shot3R 将按数据集等权计算的平均 W-MPJPE 降低 9.5%，并将平均 IDF1 绝对提高 0.099。在 EgoBody 预定义的极端视角子集上，Shot3R 将 W-MPJPE 降低 29.9%，同时保持无需未来帧或逐帧优化的逐帧流式推理。

1 引言

从一段由多个镜头组成的单目视频中恢复全局一致的多人体运动，需要在相机视角突然变化时连接不同镜头中的人体轨迹 (Pavlakos et al., 2022b; Zhang et al., 2025b; On et al., 2026)。镜头切换会打破相机运动的连续性，并显著改变人体外观，使各镜头的重建落入彼此不兼容的世界坐标系，人物身份也可能随之断裂。

本文中的“多镜头”是指单目视频中按时间依次出现的镜头片段。Shot3R 每次只接收一帧，从不联合观察同一时刻的同步多视角输入。

已有多镜头方法通常联合处理相邻镜头，或对已经观测到的完整序列进行优化 (Zhang et al., 2025b; On et al., 2026)，因而无法在帧到达时递归地产生结果。流式重建按顺序处理输入，用固定大小的状态维护历史，并避免逐视频全局优化；然而，现有方法通常假设观测在时间上连续 (Wang et al., 2025b; Chen et al., 2026b; Zhao et al., 2026)。

镜头切换由此暴露出递归历史相互冲突的作用：历史信息为镜头间对齐提供参照，但继续传播同一状态可能引起镜头内相机漂移；重新初始化避免了这种状态延续，却会失去跨镜头参照。我们的核心观察是，对齐与后续递归应被视为两个独立决策：旧状态可以临时用于估计镜头间关系，独立重新初始化的状态则负责新镜头中的重建。同一检查点下的受控实验进一步表明，跨镜头延续状态会在新镜头内部引入随时间变化的相机漂移，而不仅是一个固定坐标偏移（第 4.3 节）。

基于这一观察，我们提出 Shot3R。在镜头边界，历史条件对齐路径使用旧状态和当前图像估计镜头间变换，随后丢弃其临时状态；独立重新初始化的路径产生唯一继续传播的状态。基于预测几何的人物关联连接跨镜头身份，一个共享变换将相机与人体共同映射到已有世界坐标系。整个过程不访问未来帧、不修改已输出结果，也不执行逐视频优化。

多个多人体基准上的实验表明，Shot3R 在保持流式推理的同时改善了世界坐标人体重建、相机一致性和身份连续性，并在大视角变化下获得更明显的优势。

本文的贡献如下：

- 我们识别并通过实验刻画了递归历史在镜头切换处的冲突作用：切换前历史为镜头间对齐提供参照，继续传播同一状态可能引起镜头内相机漂移，而单独重新初始化会失去跨镜头参照。
- 我们通过临时的历史条件对齐路径与独立重新初始化的递归路径实现这种解耦，并以基于几何的人物关联和相机—人体共享变换维持空间与身份一致性。
- 在多个多人体基准上，我们改善了世界坐标人体重建、相机一致性和身份连续性；在大视角变化下优势更加明显，且无需未来帧或逐视频优化。

2 相关工作

世界坐标系人体重建。 单目人体网格恢复涵盖基于图像的回归 (Kanazawa et al., 2018)、时序建模 (Kocabas et al., 2020; Goel et al., 2023)，以及全画面多人估计 (Sun et al., 2021b; 2022; 2023; Baradel et al., 2024; Wang et al., 2025c; Sun et al., 2024)。在此基础上，世界坐标方法通过运动先验与序列优化 (Yuan et al., 2022; Ye et al., 2023; Kocabas et al., 2024; Li et al., 2024)、人体—相机联合建模 (Wang et al., 2024b; Shin et al., 2024; Shen et al., 2024; Yin et al., 2024)，或透视与尺度校准 (Patel & Black, 2025; Yang et al., 2025) 恢复全局轨迹。近期系统进一步联合重建人体与场景几何 (Müller et al., 2025; Liu et al., 2026b; Zhang et al., 2025c; Li et al., 2026a)，OnlineHMR 则研究在线世界坐标恢复 (Zhao et al., 2026)。这些方法主要假设视频在时间上连续；本文研究镜头切换破坏这种连续性后，如何维持空间与身份一致性。

有状态在线重建。 单目 SLAM 和学习式稠密建图可以增量处理视频 (Teed & Deng, 2021; Sun et al., 2021a)。DUST3R 的前馈点图预测 (Wang et al., 2024a) 进一步推动了学习式三维匹配、动态场景和图像集合几何模型 (Leroy et al., 2024; Zhang et al., 2025a; Wang et al., 2025a)。Spann3R 引入空间记忆，SLAM3R 渐进配准局部重建，CUT3R 则维护持续递归状态 (Wang & Agapito, 2025; Liu et al., 2025; Wang et al., 2025b)。Human3R 将相机、场景和多个个体纳入这一有状态范式 (Chen et al., 2026b)；UniCon3R 和 GUSH3R 分别通过接触推理和高斯表示加以扩展 (Sur et al., 2026; Abe et al., 2026)。近期方法从长序列记忆、空间状态、动态几何或状态适应等角度改进流式重建 (Chen et al., 2025; Wu et al., 2025; Zhuo et al., 2025; Chen et al., 2026a; Zheng et al., 2026; Li et al., 2026b)。它们主要研究连续观测下如何保留历史；Shot3R 则关注镜头切换产生的不兼容历史，只用旧状态完成对齐，而不把它继续传播到新镜头中。

多镜头人体重建。 多镜头重建从按时间依次出现的单目片段中恢复一致运动，不同于联合使用同步视角的多视角重建。已有工作分别研究电视剧中的跨镜头人物跟踪与重识别、跨镜头人体网格恢复、演员—环境重建、多镜头全局人体运动，以及跨镜头多人网格跟踪 (Pavlakos et al., 2022a;b;c; Zhang et al., 2025b; On et al., 2026; Kim et al., 2025)。身份一致性也与三维感知的人体跟踪以及基于外观或关键点重识别相关 (Rajasegaran et al., 2022; He et al., 2021; Yuan et al., 2025; Somers et al., 2024)；本文的人物关联只使用镜头切换后首帧预测的三




Figure 2: Shot3R 方法概览。历史条件路径估计镜头间对齐，而只有重新初始化路径传播递归状态。基于几何的跨镜头人物关联连接人物身份，共享变换将相机、人体和世界坐标场景点映射到已有世界坐标系。最右侧输出面板为示意图。

维几何。现有多镜头方法通常处理镜头对或已经获得的序列，而不是随帧到达持续更新的递归状态。同期多视角方法联合融合同时可用的多个视角，完成具有人体感知的三维重建 (Rojas et al., 2025; Yang et al., 2026; Liu et al., 2026a)。相比之下，Shot3R 每次只处理一帧，并将镜头边界视作一次递归状态转换，从而把镜头间对齐与后续状态传播解耦。

3 方法

3.1 问题定义与方法概览

给定包含镜头切换的单目视频流 $\{I_t\}_{t=1}^T$ ，Shot3R 按时间顺序预测相机姿态 C_t 和多个个体 $\mathcal{H}_t$ ，同时维护递归状态 S_t 。连续镜头内，状态提供稳定的时空参照。在镜头切换处，先前状态可以为建立两个镜头之间的关系提供参照；然而，继续传播该状态可能在新镜头内引入相机漂移，而单独重新初始化又会丢失跨镜头参照。

图像编码器将 I_t 映射为 token F_t ，检测到的人物由提示 H_t 表示。它们与初始相机 token p_0 一起，通过解码器 D_θ 和前一时刻状态交互：

$$[F'_t, p_t, H'_t], S_t = D_\theta([F_t, p_0, H_t], S_{t-1}). \quad (1)$$

更新后的 token 预测相机局部坐标系中的场景点图 P_t^c 、camera-to-world 相机姿态以及每个可见人物的 SMPL-X 参数；在齐次坐标下，世界坐标场景点图为 $P_t^w = C_t P_t^c$ 。

我们将上述在线映射简写为

$$(y_t, S_t) = f_\theta(I_t, S_{t-1}), \quad y_t = \left(C_t, P_t^w, \{J_t^i, V_t^i, q_t^i\}_{i=1}^{N_t} \right), \quad (2)$$

其中 J_t^i 、 V_t^i 和 q_t^i 分别为人物 i 的 SMPL-X (Pavlakos et al., 2019) 关节、网格顶点和匿名人物槽位。我们用预训练 Human3R 实例化 f_θ ；它的状态联合表示相机、场景几何和人物 (Chen et al., 2026b)。本文关注的是：当 I_t 不再是 S_{t-1} 所表示视频流的连续观测时，应如何转换状态并统一输出坐标。

Shot3R 将镜头间对齐与递归状态传播分离。在检测到的边界 b ，同一帧首先结合前一状态估计镜头间关系，同时从空状态独立初始化后续递归：

$$(\tilde{y}_b, \tilde{S}_b) = f_{\theta, \phi}(I_b, S_{b-1}), \quad (y_b^r, S_b^r) = f_\theta(I_b, S_\emptyset). \quad (3)$$

边界之后只传播 S_b^r 。人物关联与共享变换进一步维持世界坐标和身份一致性 (图 2)。

3.2 历史条件镜头对齐

在线镜头切换检测器只利用当前与历史 RGB 定位新镜头首帧 b 。它仅决定何时启动对齐，不估计空间变换或人物对应关系，也不访问未来帧、相机标定或人体标注；完整结构和触发策略见英文补充材料。

在检测到的边界，镜头对齐模块 Φ_ϕ 建立当前观测与上一镜头状态之间的联系。语义、相机对齐和时间上下文三种带类型的 token 分别表示当前与历史之间的视觉证据、潜在相机变化和此前的校正上下文，并与冻结主干的原生 token 一同解码。注意力汇聚首先得到当前证据 c_b 与历史记忆 m_{b-1} ：

$$\begin{aligned} z_b^{\text{sem}} &= \alpha_b c_b + (1 - \alpha_b) m_{b-1}, & z_b^{\text{cam}} &= \text{MLP}_{\text{cam}}[p_b, p_{b-1}, \Delta p_b, m_{b-1}], \\ z_b^{\text{temp}} &= \text{MLP}_{\text{temp}}[\bar{z}_{b-1}, \delta_{b-1}, g_{b-1}], & Z_b^{\text{align}} &= [z_b^{\text{sem}}, z_b^{\text{cam}}, z_b^{\text{temp}}]. \end{aligned} \quad (4)$$

其中， α_b 融合当前与历史语义证据； p 、 $\bar{z}$ 、 δ 和 g 分别表示相机 token、前一次对齐摘要、相机潜变量残差及其门控值。三种表示与人体潜变量残差分支共同使边界预测适应已有世界参照，并给出临时相机估计 $\tilde{C}_b$ ；汇聚和残差分支的完整定义见英文补充材料。

我们从共享世界坐标下的动态人体采集中构造四帧序列。镜头切换序列遵循 $A(t), A(t+1), B(t+2), B(t+3)$ ，连续序列则取同一相机的四帧；前者监督镜头间变化，后者抑制连续输入中的不必要校正。




Figure 3: 镜头对齐模块。带类型的 token 关联当前与历史证据；门控残差不向后传播。

对齐训练目标为

$$\mathcal{L}_{\text{align}} = \mathcal{L}_t + 5\mathcal{L}_R + 10\mathcal{L}_h + 0.05(\mathcal{L}_g + \mathcal{L}_{\text{imp}}) + 10^{-5}(\mathcal{R}_{\text{cam}} + \mathcal{R}_{\text{human}}), \quad (5)$$

其中 $\mathcal{L}_t$ 与 $\mathcal{L}_h$ 为相机和人体平移的 Smooth-L1 损失， $\mathcal{L}_R$ 为四元数测地距离。令 e 和 e^{raw} 分别表示归一化后的校正相机误差与未校正误差，则 $\mathcal{L}_g = \text{BCE}(g, \text{clip}(e^{\text{raw}}, 0, 1))$ ， $\mathcal{L}_{\text{imp}} = [e - e^{\text{raw}}]_+$ 。

仅三种对齐 token、相机与人体潜变量残差分支，以及预测头中的低秩适配参数 (Hu et al., 2022) 参与训练，共 19.62M 参数，占完整模型的 1.63%。图像编码器、递归主干、基础预测头和 Multi-HMR 组件 (Baradel et al., 2024) 均保持冻结。这些参数位于历史与当前观测的接口处，用于学习镜头关系，而不重新学习镜头内部重建。

3.3 分离对齐与状态传播

式 3 中两次边界计算具有不同的信息生命周期。历史条件状态 $\tilde{S}_b$ 只临时使用，新镜头后续帧仅由重新初始化路径递归更新：

$$(y_t^r, S_t^r) = f_\theta(I_t, S_{t-1}^r), \quad t > b. \quad (6)$$

因此，历史能够在边界建立明确的空间关系，却没有递归通路进入新镜头的后续状态。

重新初始化路径根据同一图像预测 C_b^r 。两条路径观察相同内容但历史条件不同，因此二者的相对相机变换可将新镜头对齐到已有世界坐标系：

$$T_b^{\text{align}} = \tilde{C}_b(C_b^r)^{-1}. \quad (7)$$

形成该变换后，历史条件路径的全部临时预测和 $\tilde{S}_b$ 均被丢弃。后续镜头切换独立重复这一操作，且不修改已输出结果。

3.4 跨镜头相机与人体一致性

T_b^{align} 首先将重新初始化路径的相机和人体预测映射到前一镜头的世界坐标系。由于相机对齐本身不能确定人物身份，Shot3R 使用预测的骨盆位置、躯干朝向和去根节点平移后的关节结构进行一对一匹配：

$$d_{ij} = \hat{d}_{\text{root}}(i, j) + \hat{d}_{\text{torso}}(i, j) + \hat{d}_{\text{joint}}(i, j). \quad (8)$$

三个代价在 Hungarian assignment (Munkres, 1957) 之前分别用其中位数归一化。匹配不使用身份标注、相机标定或未来帧；未匹配的新检测结果获得新的匿名身份。

对于匹配的前一镜头骨盆位置 r_{b-1}^i 和完成相机对齐的新镜头位置 $\bar{r}_b^j$ ，鲁棒的共享平移为

$$\Delta_b = \lambda \operatorname{median}_{(i,j) \in \mathcal{M}_b} (r_{b-1}^i - \bar{r}_b^j), \quad \lambda = 0.5. \quad (9)$$

固定系数 λ 在仅相机对齐和完整人物位移之间进行插值，并在所有数据集上保持不变。历史条件路径的相机确定方向和初始世界关系，匹配人物的位移进一步调整共享平移，同时保持相机—人体相对几何不变。

令 $T_b^\Delta = \begin{bmatrix} I_3 & \Delta_b \\ \mathbf{0}^\top & 1 \end{bmatrix}$ 且 $T_b = T_b^\Delta T_b^{\text{align}}$ ，最终输出为

$$C_t' = T_b C_t^r, \quad P_t'^w = T_b P_t^{r,w}, \quad J_t'^i = T_b J_t^{r,i}, \quad V_t'^i = T_b V_t^{r,i}, \quad q_t'^i = \pi_b(q_t^{r,i}), \quad S_t' = S_t^r. \quad (10)$$

因此，相机、世界坐标场景点和人体共享同一个世界变换；相机局部点图不发生形变，递归状态既不接受该变换，也不从前一镜头复制。后续每个边界都相对于累积世界坐标系估计新的变换；组合变换只影响当前与未来输出，已经输出的帧保持不变。

4 实验

我们在统一世界坐标系中评测多镜头多人体重建，重点分析大视角变化、对齐与状态传播、人物关联、镜头切换检测和效率。

4.1 实验设置

对比方法。 Human3R 是主要的受控基线：两种方法接收完全相同、按时间排序的 RGB 帧，并使用相同评测；区别在于 Human3R 跨镜头不间断传播状态，而 Shot3R 在检测到切换后先对齐镜头，再将重新初始化的状态传播到新镜头后续帧。我们还运行 OnlineHMR、TRACE、PromptHMR、JOSH 和 TRAM 的公开实现 (Zhao et al., 2026; Sun et al., 2023; Wang et al., 2025c; Liu et al., 2026b; Wang et al., 2024b)。表 1 按时间访问方式组织这些方法。OnlineHMR 结合半在线人物跟踪与独立的全局相机后端；PromptHMR 和 JOSH 处理完整视频；TRAM 纳入统一的完整系统计时。HumanMM 和 Multi-THuMBS 没有公开在本文固定输入上复现实验所需的完整代码、权重和配置，因此仅在英文补充材料中概括其任务范围，不混用不同协议下的论文数值。

数据集与指标。 我们将 EgoBody、EgoHumans 和 Harmony4D 的同步采集 (Zhang et al., 2022; Khirodkar et al., 2023; 2024) 转换为按时间依次出现的两段单目 RGB 流，分别包含 129、90 和 88 个固定样例。模型每次仅接收一帧按时间排序的输入。三个数据集提供互补的实验依据：EgoBody 用于受控机制消融，EgoHumans 侧重大视角变化与递归状态延续，Harmony4D 用于评估人物关联与重复镜头切换。

W-MPJPE (W) 根据最早有效观测确定并固定 Sim(3) 对齐，因此对跨镜头轨迹偏移敏感；WA-MPJPE (WA) 使用全部有效观测进行 Sim(3) 对齐。相机误差在 EgoBody/Harmony4D 上使用 ATE-Sim3，在 EgoHumans 上使用 ATE-SE3。IDF1 评估身份连续性 (Ristani et al., 2016)，Coverage 用于暴露不会进入条件人体误差统计的缺失预测。绝对误差只在同一数据集内比较。

实现细节。 我们使用 AvatarReX 和 THuman 训练 19.62M 个对齐参数，其余模型保持冻结。每个数据源提供 8000 段切换序列和 2000 段连续四帧序列，并以 0.6/0.4 的概率采样。AdamW (Loshchilov & Hutter, 2019) 共更新 7200 次，batch size 为 10，输入分辨率为 512。所有评测统一使用第 72 轮检查点、 $\lambda = 0.5$ 和同一推理配置，不执行针对数据集或单个视频的优化。

4.2 多镜头多人体重建

总体结果。 表 1 给出 EgoBody 和 EgoHumans 结果，Harmony4D 的完整比较见英文补充材料。在三个数据集上，相比 Human3R，Shot3R 均改善 WA、相机误差和 IDF1。在 EgoBody 上，W/WA 从 321.1/233.4 mm 降至 258.8/201.7 mm，ATE 从 0.124 m 降至 0.016 m，IDF1 从




Figure 4: 跨镜头切换的关键定性比较。每一行首先展示切换前后的输入，随后依次给出 OnlineHMR、JOSH、Human3R 和 Shot3R 的结果。视角变化从上到下为 134.36° 、 149.85° 和 176.75° 。Shot3R 保持更连贯的相机—人体布局；方法能够输出场景几何时一并显示。完整七方法版本见英文补充材料。

Table 1: EgoBody 与 EgoHumans 多镜头多人体重建协议上的比较。

类别	方法	切换处理	EgoBody ($N = 129$)					EgoHumans ($N = 90$)				
			W ↓	WA ↓	ATE ↓	IDF1 ↑	覆盖率 ↑	W ↓	WA ↓	ATE ↓	IDF1 ↑	覆盖率 ↑
离线	PromptHMR (SPEC)	×	741.4 ⁶⁴	336.1 ⁸⁷	—	0.195	0.202	1193.3 ¹⁷	487.7 ²⁵	—	0.061	0.062
	JOSH	×	399.6 ¹²⁷	322.9 ¹²⁷	0.087 ¹²⁷	0.973	0.980	1410.7 ⁷⁷	481.3 ⁷⁷	1.755 ⁸⁷	0.616	0.686
半在线	OnlineHMR	×	961.2 ⁹⁷	418.1 ⁹⁷	0.259 ¹²⁹	0.375	0.424	1311.7 ⁵⁰	405.5 ⁵⁰	3.869 ⁸⁷	0.142	0.211
在线	TRACE	×	576.4 ²²	276.4 ³⁵	—	0.036	0.035	2464.6 ⁴³	749.5 ⁵⁹	—	0.070	0.072
	Human3R	×	321.1	233.4	0.124	0.870	0.981	1005.1	365.7	1.673	0.471	0.639
	Shot3R	✓	258.8	201.7	0.016	0.985	0.981	866.8	336.9	1.423	<u>0.571</u>	0.616

“切换处理”表示方法是否显式处理镜头切换。W/WA 单位为 mm，ATE 单位为 m (EgoBody 使用 Sim(3)，EgoHumans 使用 SE(3))。上标表示条件几何指标的可评测视频数；IDF1 与 Coverage 使用完整预定义协议。不同有效样本集合上的条件几何均值不能构成统一排名。

0.870 提升至 0.985，Coverage 同为 0.981。局部姿态与人体网格精度基本保持不变，说明主要收益来自世界坐标配准、相机估计和身份连续性，而非重新学习镜头内部的人体重建。

图 4 展示了 134.36° 、 149.85° 和 176.75° 的镜头切换。尽管视角和人体外观显著变化，Shot3R 仍能维持更连贯的相机—人体布局；相应方法能够输出场景几何时一并显示。

在三个数据集上，Shot3R 相比 Human3R 均改善了 WA、相机轨迹精度和 IDF1；W 在 EgoBody 和 EgoHumans 上得到改善，而在 Harmony4D 上略有上升。完整的分数据集结果和镜头边界诊断见英文补充材料。

大视角变化。 按数据集等权汇总时，Shot3R 在全部视角下将 W/WA 分别降低 9.5%/8.8%，并将 IDF1 提高 0.099；在预定义的大视角子集上，改善更加明显，分别达到 19.1%/18.7% 和 0.195。EgoBody 极端视角子集中，W 从 505.1 mm 降至 354.3 mm (29.9%)，IDF1 从 0.758 提升至 0.983。完整的分数据集视角区间结果与连续角度分析见英文补充材料；这些结果并不说明每项指标都随视角变化单调改善。

与公开方法比较。 在双方均可评测的相同输入上，Shot3R 相对 OnlineHMR 具有更低的人体与相机误差，并在全部视频上获得更高的 IDF1/Coverage；除 EgoHumans WA 外，配对区间均不跨越零。在 Shot3R 与离线 JOSH 共同可评测的样本上，Shot3R 在三个数据集上的 W、WA 和 ATE 均更低，且不访问未来帧。TRACE 与 PromptHMR 分别只在 22/35 和 64/87 段 EgoBody 视频上返回可评测 W/WA，因此解释其条件误差时必须同时考虑有效样本数。




Figure 5: **EgoHumans** 中的视角响应。曲线给出四个固定视角区间内的 W-MPJPE 和 IDF1 绝对值，阴影为以 capture 为单位 bootstrap 得到的 95% 置信区间。Shot3R 在全部区间均提高 IDF1，并在 130° 和 177° 时明显降低 W-MPJPE。




Figure 6: 跨镜头延续旧状态会导致新镜头内部的相机漂移。在静态相机采集中，相同的未修改 Human3R 检查点处理完全相同的新镜头 RGB，且不使用 Shot3R 模块。首个预测锚定消除固定坐标变换后，旧状态延续仍产生漂移，而重新初始化保持稳定。

4.3 分析与消融实验

镜头间对齐与状态传播。 只重新初始化状态会失去跨镜头世界坐标参照，使 EgoBody W/WA 从 321.1/233.4 mm 上升到 752.6/589.4 mm。为了单独检验旧状态的干扰，我们在 90 个静态物理相机的 EgoHumans 样例中，使用同一原始 Human3R 检查点处理完全相同的切换后 RGB 帧；两个控制均不使用 Shot3R 模块。两条轨迹都锚定于新镜头的首个预测，以消除固定坐标变换。后续 16 帧中，状态延续产生 1.124 m/14.58° 的相机漂移，重新初始化后仅为 0.026 m/0.20°，且后者在全部 27 个 capture 上都更低。配对均值差为 1.098 m [0.832, 1.372] 和 14.38° [8.92°, 20.49°]，两个单侧配对检验均有 $p = 7.45 \times 10^{-9}$ 。这说明旧状态引入的是新镜头内部随时间变化的误差，而不只是固定坐标偏移。

在相同标注边界和学习式对齐下，两种控制只改变对齐后传播的状态，并具有相同的首帧对齐误差。关闭人物关联与人物引导平移后，延续状态有利于世界坐标人体估计（W/WA 为 293.3/227.3 mm，而重新初始化为 352.8/267.7 mm），重新初始化则将序列 ATE 从 0.082 m 降至 0.017 m；43 个 recording 上的配对 ATE 差为 0.065 m [0.049, 0.085]。因此，两种状态选择都不是全面更优。完整系统组合重新初始化递归、人物关联和共享变换，达到 258.8/201.7 mm W/WA、0.016 m ATE 和 0.985 IDF1，是表 2 中最好的联合结果。由于该行评测完整设计，其收益不能仅归因于状态选择。这两组控制共同支持将对齐与递归状态传播视为两个独立决策。

人物关联。 在 Harmony4D 上，骨盆位置已经能够提供有效的人物关联；进一步加入躯干朝向和去根节点后的关节结构，使身份延续率从 78.41% 提升至 80.68%，IDF1 从 0.620 提升至 0.635，说明这些预测几何线索具有互补作用。人物关联在本文中是镜头间对齐之后的轻量支持机制。

重复镜头切换。 英文补充材料中的小规模三镜头受控实验验证了同一状态转换可以重复执行，并完整报告相应的指标权衡。

镜头检测与效率。 检测器在 EgoBody、EgoHumans 和 Harmony4D 的全部正式样例上，首次触发均与标注边界一致。标准化重建计时包含模型推理、输出解码、人物关联和世界坐标配准，但不包含模型加载、RGB 读取与缩放以及自动镜头检测。在单张 NVIDIA L20 上，

Table 2: EgoBody 上的对齐—状态传播 2×2 受控实验及完整 Shot3R。

设置	边界信号	镜头切换操作			EgoBody 指标			
		传播	状态	人物关联	W (mm) ↓	WA (mm) ↓	ATE (m) ↓	IDF1 ↑
Human3R	—	×	延续	×	321.1	233.4	0.124	0.870
状态重新初始化	标注	×	重新初始化	×	752.6	589.4	1.141	0.834
对齐 + 延续状态	标注	✓	延续	×	293.3	227.3	0.082	0.868
对齐 + 重新初始化状态	标注	✓	重新初始化	×	352.8	267.7	0.017	0.834
Shot3R	检测	✓	重新初始化	✓	258.8	201.7	0.016	0.985

三个受控设置使用标注边界，Human3R 不接收边界信号。两个包含对齐的受控设置均关闭显式人物关联和人物引导共享平移，因此二者只改变对齐后传播的状态。

Shot3R 处理一次镜头切换时达到 3.106 FPS，而 Human3R 为 3.224 FPS，对应约 3.8% 的额外时间。每次镜头切换只在新镜头第一帧增加一次额外神经网络计算；完整系统计时与切换数量分析见英文补充材料。

5 结论

本文研究了递归历史在镜头切换处的冲突作用：切换前历史为建立连续镜头之间的关系提供参照，但将同一状态继续传播到新镜头可能引起随时间变化的镜头内漂移，而单独重新初始化又会丢失跨镜头参照。Shot3R 只在临时对齐路径中使用历史，独立重新初始化的状态则负责后续递归。基于预测几何的人物关联连接跨镜头身份，共享变换将相机、人体和场景预测映射到统一世界坐标系。

受控实验支持将对齐与状态传播视为两个独立决策。在三个基准上，相比连续状态递归，Shot3R 均改善了 WA-MPIPE、相机轨迹精度和 IDF1，并在大视角变化下获得最明显的收益。这些改进无需未来帧或逐视频优化；在包含一次镜头切换的标准化重建测试中，相比 Human3R 仅增加 3.8% 的时间。更进一步，我们的结果表明，递归历史可以作为镜头间对齐的临时坐标参照，而不必作为新镜头的递归状态继续传播。复杂剪辑、人物反复进出画面以及快速视觉变化仍是开放问题。

AI 使用声明

本文在规划、文字编辑、分析支持、代码框架搭建，以及可编辑矢量图的布局和标注过程中使用了语言模型辅助。语言模型没有合成评测输入、重建结果面板、真值或数值测量。作者检查了底层记录，并对每项实验协议、结果、图、引用和论断负责。

伦理声明

本文使用的人体采集数据集均为公开数据或获得研究许可的数据，并遵循数据提供方的知情同意、访问和科研使用条件。我们不推断参与者身份，不跨数据集关联参与者，也不将这些材料用于监控。受限图像、标注和模型权重保存在访问受控的存储中，并在许可禁止时不进行重新分发。

可复现性声明

我们保留固定的评测定义、评测代码、逐样本记录、方法—代码映射、流式输入检查、使用相同权重的状态隔离实验、对齐—状态传播受控实验、按视角聚类的统计、人物关联线索消融和重复镜头切换实验。论文表格由带有来源哈希的机器可读汇总生成。完整复现还需要获得许可的数据和检查点；在许可允许的范围内，发布材料将包含代码、协议清单、汇总测量和不含身份信息的样本标识符。

参考文献

- Keito Abe, Kaede Shiohara, Takashi Otonari, and Toshihiko Yamasaki. GUSH3R: Everyone everywhere all at once as gaussians, 2026. URL <https://arxiv.org/abs/2607.05243>.
- Fabien Baradel, Matthieu Armando, Salma Galaaoui, Romain Brégier, Philippe Weinzaepfel, Grégory Rogez, and Thomas Lucas. Multi-HMR: Multi-person whole-body human mesh recovery in a single shot. In *European Conference on Computer Vision*, 2024.
- Xingyu Chen, Yue Chen, Yuliang Xiu, Andreas Geiger, and Anpei Chen. TTT3R: 3d reconstruction as test-time training. In *International Conference on Learning Representations*, 2026a. URL <https://arxiv.org/abs/2509.26645>.
- Yue Chen, Xingyu Chen, Yuxuan Xue, Anpei Chen, Yuliang Xiu, and Gerard Pons-Moll. Human3R: Everyone everywhere all at once. In *International Conference on Learning Representations*, 2026b. URL <https://arxiv.org/abs/2510.06219>.
- Zhuoguang Chen, Minghui Qin, Tianyuan Yuan, Zhe Liu, and Hang Zhao. Long3R: Long sequence streaming 3d reconstruction, 2025. URL <https://arxiv.org/abs/2507.18255>.
- Shubham Goel, Georgios Pavlakos, Jathushan Rajasegaran, Angjoo Kanazawa, and Jitendra Malik. Humans in 4d: Reconstructing and tracking humans with transformers. In *IEEE/CVF International Conference on Computer Vision*, pp. 14783–14794, 2023.
- Shuting He, Hao Luo, Pichao Wang, Fan Wang, Hao Li, and Wei Jiang. TransReID: Transformer-based object re-identification. In *IEEE/CVF International Conference on Computer Vision*, 2021. doi: 10.1109/ICCV48922.2021.01474.
- Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022.
- Angjoo Kanazawa, Michael J. Black, David W. Jacobs, and Jitendra Malik. End-to-end recovery of human shape and pose. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 7122–7131, 2018. doi: 10.1109/CVPR.2018.00744.
- Rawal Khirodkar, Aayush Bansal, Lingni Ma, Richard Newcombe, Minh Vo, and Kris Kitani. Ego-Humans: An egocentric 3d multi-human benchmark. In *IEEE/CVF International Conference on Computer Vision*, 2023. URL <https://arxiv.org/abs/2305.16487>.
- Rawal Khirodkar, Jyun-Ting Song, Jinkun Cao, Zhengyi Luo, and Kris Kitani. Harmony4D: A video dataset for in-the-wild close human interactions. In *Advances in Neural Information Processing Systems*, 2024. URL <https://arxiv.org/abs/2410.20294>.
- Sangmin Kim, Seunguk Do, and Jaesik Park. ShowMak3r: Compositional tv show reconstruction. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. URL <https://arxiv.org/abs/2504.19584>.
- Muhammed Kocabas, Nikos Athanasiou, and Michael J. Black. VIBE: Video inference for human body pose and shape estimation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020. URL <https://arxiv.org/abs/1912.05656>.
- Muhammed Kocabas, Ye Yuan, Pavlo Molchanov, Yunrong Guo, Michael J. Black, Otmar Hilliges, Jan Kautz, and Umar Iqbal. PACE: Human and camera motion estimation from in-the-wild videos. In *International Conference on 3D Vision*, pp. 397–408, 2024.
- Vincent Leroy, Yohann Cabon, and Jerome Revaud. Grounding image matching in 3d with MAST3R. In *European Conference on Computer Vision*, 2024. doi: 10.1007/978-3-031-73220-1_5.
- Jiefeng Li, Ye Yuan, Davis Rempe, Haotian Zhang, Pavlo Molchanov, Cewu Lu, Jan Kautz, and Umar Iqbal. COIN: Control-inpainting diffusion prior for human and camera motion estimation. In *European Conference on Computer Vision*, pp. 426–446, 2024. doi: 10.1007/978-3-031-72640-8_24.

- Mengfei Li, Peng Li, Zheng Zhang, Jiahao Lu, Chengfeng Zhao, Wei Xue, Qifeng Liu, Sida Peng, Wenxiao Zhang, Wenhan Luo, Yuan Liu, and Yike Guo. UniSH: Unifying scene and human reconstruction in a feed-forward pass. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026a. URL <https://arxiv.org/abs/2601.01222>.
- Xinze Li, Yiyuan Wang, Pengxu Chen, Wentao Fan, Weifeng Su, Weisi Lin, and Wentao Cheng. ReCal3R: Reliability-calibrated learning rates for streaming 3d reconstruction, 2026b. URL <https://arxiv.org/abs/2607.05356>.
- Jinpeng Liu, Yukang Xu, Yutong Li, and Xingyu Liu. TROPHIES: Temporal reconstruction of places, humans, and cameras from multi-view videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 21154–21164, 2026a. URL <https://arxiv.org/abs/2606.02350>.
- Yuzheng Liu, Siyan Dong, Shuzhe Wang, Yingda Yin, Yanchao Yang, Qingnan Fan, and Baoquan Chen. SLAM3R: Real-time dense scene reconstruction from monocular RGB videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. doi: 10.1109/CVPR52734.2025.01552.
- Zhizheng Liu, Joe Lin, Wayne Wu, and Bolei Zhou. Joint optimization for 4d human–scene reconstruction in the wild. In *International Conference on Learning Representations*, 2026b. URL <https://arxiv.org/abs/2501.02158>.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019. URL <https://openreview.net/forum?id=Bkg6RiCqY7>.
- Lea Müller, Hongsuk Choi, Anthony Zhang, Brent Yi, Jitendra Malik, and Angjoo Kanazawa. Reconstructing people, places, and cameras. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 21948–21958, 2025.
- James Munkres. Algorithms for the assignment and transportation problems. *Journal of the Society for Industrial and Applied Mathematics*, 5(1):32–38, 1957.
- Jeongwan On, Muhammad Salman Ali, Muneeb A. Khan, Sunwoo Park, Inwoong Moon, Hyung Jin Chang, Jaekwang Kim, Seong Jong Ha, and Seungryul Baek. Multi-THuMBS: Multi-person tracking of 3d human meshes beyond video shots, 2026. URL <https://arxiv.org/abs/2607.01626>.
- Priyanka Patel and Michael J. Black. CameraHMR: Aligning people with perspective. In *International Conference on 3D Vision*, 2025. doi: 10.1109/3DV66043.2025.00146.
- Georgios Pavlakos, Vasileios Choutas, Nima Ghorbani, Timo Bolkart, Ahmed A. A. Osman, Dimitrios Tzionas, and Michael J. Black. Expressive body capture: 3d hands, face, and body from a single image. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019. URL <https://arxiv.org/abs/1904.05866>.
- Georgios Pavlakos, Angjoo Kanazawa, Jitendra Malik, Michael J. Black, and Kostas Daniilidis. Multi-shot person tracking and re-identification in TV series. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022a.
- Georgios Pavlakos, Jitendra Malik, and Angjoo Kanazawa. Human mesh recovery from multiple shots. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022b. URL <https://arxiv.org/abs/2012.09843>.
- Georgios Pavlakos, Ethan Weber, Matthew Tancik, and Angjoo Kanazawa. The one where they reconstructed 3d humans and environments in TV shows. In *European Conference on Computer Vision*, pp. 732–749, 2022c.
- Jathushan Rajasegaran, Georgios Pavlakos, Angjoo Kanazawa, and Jitendra Malik. Tracking people by predicting 3d appearance, location and pose. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022. doi: 10.1109/CVPR52688.2022.00276.

- Ergys Ristani, Francesco Solera, Roger Zou, Rita Cucchiara, and Carlo Tomasi. Performance measures and a data set for multi-target, multi-camera tracking. In *European Conference on Computer Vision Workshops*, 2016.
- Sara Rojas, Matthieu Armando, Bernard Ghanem, Philippe Weinzaepfel, Vincent Leroy, and Gregory Rogez. HAMSt3R: Human-aware multi-view stereo 3d reconstruction. In *IEEE/CVF International Conference on Computer Vision*, 2025. doi: 10.1109/ICCV51701.2025.00478.
- Zehong Shen, Huaijin Pi, Yan Xia, Zhi Cen, Sida Peng, Zechen Hu, Hujun Bao, Ruizhen Hu, and Xiaowei Zhou. World-grounded human motion recovery via gravity-view coordinates, 2024. URL <https://arxiv.org/abs/2409.06662>.
- Soyong Shin, Juyong Kim, Eni Halilaj, and Michael J. Black. WHAM: Reconstructing world-grounded humans with accurate 3d motion. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024. URL <https://arxiv.org/abs/2312.07531>.
- Vladimir Somers, Christophe De Vleeschouwer, and Alexandre Alahi. Keypoint promptable re-identification. In *European Conference on Computer Vision*, 2024.
- Jiaming Sun, Yiming Xie, Linghao Chen, Xiaowei Zhou, and Hujun Bao. NeuralRecon: Real-time coherent 3d reconstruction from monocular video. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 15598–15607, 2021a.
- Qingping Sun, Yanjun Wang, Ailing Zeng, Wanqi Yin, Chen Wei, Wenjia Wang, Haiyi Mei, Chi-Sing Leung, Lei Yang, Ziwei Liu, and Zhongang Cai. AiOS: All-in-one-stage expressive human pose and shape estimation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024. doi: 10.1109/CVPR52733.2024.00180.
- Yu Sun, Qian Bao, Wu Liu, Yili Fu, Michael J. Black, and Tao Mei. Monocular, one-stage, regression of multiple 3d people. In *IEEE/CVF International Conference on Computer Vision*, pp. 11179–11188, 2021b.
- Yu Sun, Wu Liu, Qian Bao, Yili Fu, Tao Mei, and Michael J. Black. Putting people in their place: Monocular regression of 3d people in depth. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 13243–13252, 2022.
- Yu Sun, Qian Bao, Wu Liu, Tao Mei, and Michael J. Black. TRACE: 5d temporal regression of avatars with dynamic cameras in 3d environments. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023. URL <https://arxiv.org/abs/2306.02850>.
- Tanuj Sur, Shashank Tripathi, Nikos Athanasiou, Ha Linh Nguyen, Kai Xu, Michael J. Black, and Angela Yao. UniCon3R: Unified contact-aware 4d human-scene reconstruction from monocular video, 2026. URL <https://arxiv.org/abs/2604.19923>.
- Zachary Teed and Jia Deng. DROID-SLAM: Deep visual SLAM for monocular, stereo, and RGB-D cameras. In *Advances in Neural Information Processing Systems*, volume 34, pp. 16558–16569, 2021.
- Hengyi Wang and Lourdes Agapito. 3d reconstruction with spatial memory. In *International Conference on 3D Vision*, 2025. doi: 10.1109/3DV66043.2025.00013.
- Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual geometry grounded transformer. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025a.
- Qianqian Wang, Yifei Zhang, Aleksander Holynski, Alexei A. Efros, and Angjoo Kanazawa. Continuous 3d perception model with persistent state, 2025b. URL <https://arxiv.org/abs/2501.12387>.
- Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. DUST3R: Geometric 3d vision made easy. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024a. URL <https://arxiv.org/abs/2312.14132>.

- Yufu Wang, Ziyun Wang, Lingjie Liu, and Kostas Daniilidis. TRAM: Global trajectory and motion of 3d humans from in-the-wild videos. In *European Conference on Computer Vision*, 2024b. URL <https://arxiv.org/abs/2403.17346>.
- Yufu Wang, Yu Sun, Priyanka Patel, Kostas Daniilidis, Michael J. Black, and Muhammed Kocabas. PromptHMR: Promptable human mesh recovery. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025c. URL <https://arxiv.org/abs/2504.06397>.
- Yuqi Wu, Wenzhao Zheng, Jie Zhou, and Jiwen Lu. Point3R: Streaming 3d reconstruction with explicit spatial pointer memory, 2025. URL <https://arxiv.org/abs/2507.02863>.
- Fengyuan Yang, Kerui Gu, Ha Linh Nguyen, Tze Ho Elden Tse, and Angela Yao. Humans as checkerboards: Calibrating camera motion scale for world-coordinate human mesh recovery. In *IEEE/CVF International Conference on Computer Vision*, 2025. doi: 10.1109/ICCV51701.2025.00573.
- Yuanwang Yang, Buzhen Huang, Zongxuan Ren, Jing Huang, and Kun Li. Feed-forward multi-view multi-person reconstruction with contrastive human-aware 3d representation. *International Journal of Computer Vision*, 134(9):414, 2026. doi: 10.1007/s11263-026-03000-0. URL <https://doi.org/10.1007/s11263-026-03000-0>.
- Vickie Ye, Georgios Pavlakos, Jitendra Malik, and Angjoo Kanazawa. Decoupling human and camera motion from videos in the wild, 2023. URL <https://arxiv.org/abs/2302.12827>.
- Wanqi Yin, Zhongang Cai, Ruisi Wang, Fanzhou Wang, Chen Wei, Haiyi Mei, Weiye Xiao, Zhitao Yang, Qingping Sun, Atsushi Yamashita, Ziwei Liu, and Lei Yang. WHAC: World-grounded humans and cameras, 2024. URL <https://arxiv.org/abs/2403.12959>.
- Chao Yuan, Guiwei Zhang, Changxiao Ma, Tianyi Zhang, and Guanglin Niu. From poses to identity: Training-free person re-identification via feature centralization. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. doi: 10.1109/CVPR52734.2025.02273.
- Ye Yuan, Umar Iqbal, Pavlo Molchanov, Kris Kitani, and Jan Kautz. GLAMR: Global occlusion-aware human mesh recovery with dynamic cameras. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022. URL <https://arxiv.org/abs/2112.01524>.
- Junyi Zhang, Charles Herrmann, Junhwa Hur, Varun Jampani, Trevor Darrell, Forrester Cole, Deqing Sun, and Ming-Hsuan Yang. MonST3R: A simple approach for estimating geometry in the presence of motion. In *International Conference on Learning Representations*, 2025a.
- Siwei Zhang, Qianli Ma, Yan Zhang, Zhiyin Qian, Taein Kwon, Marc Pollefeys, Federica Bogo, and Siyu Tang. EgoBody: Human body shape and motion of interacting people from head-mounted devices. In *European Conference on Computer Vision*, 2022. URL <https://arxiv.org/abs/2112.07642>.
- Yuhong Zhang, Guanlin Wu, Ling-Hao Chen, Zhuokai Zhao, Jing Lin, Xiaoke Jiang, Jiamin Wu, Zhuoheng Li, Hao Frank Yang, Haoqian Wang, and Lei Zhang. HumanMM: Global human motion recovery from multi-shot videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025b. URL <https://arxiv.org/abs/2503.07597>.
- Zetong Zhang, Manuel Kaufmann, Lixin Xue, Jie Song, and Martin R. Oswald. OHSR: Online dense 3d reconstruction of humans and scenes from monocular videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025c. doi: 10.1109/CVPR52734.2025.02033.
- Yiwen Zhao, Ce Zheng, Yufu Wang, Hsueh-Han Daniel Yang, Liting Wen, and Laszlo A. Jeni. OnlineHMR: Video-based online world-grounded human mesh recovery. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. URL <https://arxiv.org/abs/2603.17355>.
- Zhijie Zheng, Xinhao Xiang, and Jiawei Zhang. TTSA3R: Training-free temporal-spatial adaptive persistent state for streaming 3d reconstruction, 2026. URL <https://arxiv.org/abs/2601.22615>.
- Dong Zhuo, Wenzhao Zheng, Jiahe Guo, Yuqi Wu, Jie Zhou, and Jiwen Lu. Streaming 4d visual geometry transformer, 2025. URL <https://arxiv.org/abs/2507.11539>.