

Shot3R: 基于多镜头状态转移的流式四维人体一场景重建

Anonymous authors

Paper under double-blind review



Figure 1: Shot3R 将依次到达的单目镜头流式重建到统一世界坐标系中，同时维持相机、人体运动和人物身份的连续性。角度表示相对于第一镜头的源相机旋转。

Abstract

从包含镜头切换的单目视频中进行流式多人四维重建，需要将连续镜头中的相机轨迹、人体和场景几何置于统一世界坐标系中。现有在线递归方法通过持续传递递归状态增量更新重建结果，但这一过程通常依赖相邻观测之间的视觉与几何连续性。然而，在镜头边界处，先前状态具有相互冲突的作用：它为建立新镜头与累积重建之间的空间关系提供参照，却不再适合作为新镜头内的递归条件。继续传播这一状态可能干扰新镜头的估计，而将其重置又会丢失跨镜头的空间关系。为解决这一冲突，**Shot3R** 将每次镜头切换表述为一种历史条件的在线状态转移。在每个边界处，Shot3R 在潜在空间中联合建模历史表示与当前观测，以推断新镜头与已有重建之间的空间关系，同时为新镜头初始化独立的递归状态。该边界推断为相机轨迹、人体运动和场景几何建立一致的世界坐标表征；基于几何的人物关联维持跨镜头身份一致性，后续仅传播新镜头状态。在三个多人基准上的受控比较中，相较于连续状态传播，Shot3R 将按数据集等权计算的平均 W-MPJPE 降低了 9.5%，并将平均 IDF1 绝对提高了 0.099。在 EgoBody 预定义的极端视角子集上，W-MPJPE 降低了 29.9%。在相同多镜头输入上与公开在线及离线重建系统的进一步比较表明，Shot3R 取得了具有竞争力的重建精度。

1 引言

近年来，流式四维重建方法已经能够在顺序处理单目视频的过程中，联合恢复人体运动、相机轨迹和场景几何 (Wang et al., 2025b; Chen et al., 2026b; Sur et al., 2026)。这些方法将历史观测压缩到递归状态中，从而实现高效的在线推理，但其建模通常假设相邻帧来自一次连续拍摄。经过剪辑的视频经常违背这一假设：它们由时间上依次出现的多个镜头组成，镜头之间的切换可能突然改变视角、消除视觉重叠，并显著改变可见场景与人体外观 (Pavlakos et al., 2022b; Zhang et al., 2025b; On et al., 2026)。因此，在边界之前积累的历史可能不再适合作为

新镜头的递归上下文。本文研究这种非连续输入下的流式重建。这里的“多镜头”是指单目视频中依次出现的镜头片段，而不是同一时刻的同步多视角观测。我们的目标是将每个镜头中的相机轨迹、重建人体和场景几何表示在一个统一世界坐标系中；该坐标系由第一镜头初始化，并作为整段序列共享的重建参考系。

现有方法只解决了这一问题的一个方面。多镜头人体重建方法通过联合处理多个已有镜头或进行序列级优化，在镜头切换前后建立人物关系 (Pavlakos et al., 2022b; Zhang et al., 2025b; On et al., 2026)。这些方法能够有效恢复跨镜头结构，但通常并非为仅依靠有限递归状态、且不访问未来帧的逐步预测而设计。有状态在线重建方法提供了与之互补的能力：它们按照时间顺序处理输入，并避免逐视频的全局优化 (Wang et al., 2025b; Chen et al., 2026b; 2025)。然而，其递归状态被设计为在连续观测中逐步演化，并没有显式处理历史有效性在镜头边界处突然改变的情况。因此，这两类方法都没有直接满足本文的核心需求：在保留先前镜头所建立空间参照的同时，避免将不兼容的历史继续传播到新镜头的重建过程中。

这一缺口源于递归历史在镜头边界处的使用冲突。跨越边界继续传播状态，可以保留先前观测所建立的坐标参照，却也迫使新镜头与在非连续视角下积累的历史发生交互；切换处引入的误差因而可能在后续递归更新中持续传播。重新初始化状态可以消除这种干扰，使新镜头内部恢复连贯的递归重建，但同时也会抹去将该镜头定位到统一世界坐标系所需的参照。因此，关键问题并不是应该保留还是丢弃历史，而是历史的哪些作用应当跨越镜头边界继续存在。我们的核心观察是，历史只应作为临时的对齐参照继续发挥作用：它可以被读取以建立镜头间关系，但不应作为新镜头的递归状态继续传播。使用相同重建模型进行的受控比较支持这一判断：状态延续造成的是随时间变化的相机漂移，而不只是一次固定偏移；独立重建则能够保持新镜头内部的连贯性，却失去了与先前世界坐标系的空间关系（第 4.3 节）。

为解决这一冲突，我们提出 Shot3R：一个为递归历史的两种作用赋予不同信息生命周期的流式重建框架。在每个镜头边界处，Shot3R 临时读取先前状态以推断镜头间的空间关系，但不会将这一过程产生的状态保留为后续重建所使用的记忆。新镜头内部的递归过程从独立初始化的状态开始，并且只有该状态会继续向后传播。在建立空间关系之后，基于几何的人物关联维持镜头边界两侧的身份连续性，相机—人体共享变换则将新镜头的重建结果表示到统一世界坐标系中。Shot3R 不需要访问未来帧、修改已经输出的估计结果或执行逐视频优化。在三个多人体基准上，相比连续传播历史状态，Shot3R 将按数据集等权计算的平均 W-MPJPE 降低了 9.5%，并一致改善了相机精度和身份连续性；在 EgoBody 预定义的极端视角子集上，W-MPJPE 的降幅达到 29.9%。

本文的主要贡献如下：

- 我们识别并刻画了递归历史在镜头边界处的使用冲突：历史是建立相邻镜头关系所必需的参照，但将其继续传播到新镜头可能引入持续的重建误差，而将其完全丢弃又会失去镜头间的空间参照。
- 我们提出 Shot3R，一个将“读取历史以进行对齐”与“传播状态以完成重建”分开处理的流式多镜头重建框架。Shot3R 仅将边界之前的历史保留为临时参照，并通过独立初始化的递归状态推进新镜头的重建，同时维持镜头边界两侧的空间与身份一致性。
- 通过使用相同重建模型的受控比较以及三个多人体基准上的评测，我们证明这种分离能够改善世界坐标人体重建、相机精度和身份连续性，并在大幅视角变化下取得最明显的收益，同时不需要访问未来帧或执行逐视频优化。

2 相关工作

全局人体运动重建。 人体网格恢复已经从参数化人体模型拟合，逐渐发展为从单目图像和视频直接进行前馈式回归 (Kanazawa et al., 2018; Kocabas et al., 2020; Goel et al., 2023)。基于图像的方法主要在相机坐标系中估计人体姿态和形状，而时序模型与全画面多人方法进一步改善了运动一致性以及拥挤场景中的多人推理能力 (Sun et al., 2021b; 2022; 2023; Baradel et al., 2024; Wang et al., 2025c; Sun et al., 2024)。然而，当相机本身发生运动时，相机坐标系下的预测无法直接描述人体在三维环境中的全局运动。为此，现有方法通过运动先验与序列优化 (Yuan et al., 2022; Ye et al., 2023; Kocabas et al., 2024; Li et al., 2024)、人体—相机联合建模 (Wang et al., 2024b; Shin et al., 2024; Shen et al., 2024; Yin et al., 2024)、或透视关系与尺度标定 (Patel & Black, 2025; Yang et al., 2025)，共同恢复人体轨迹和相机运动；近期系统还将人体、相机和周围场景几何纳入统一重建 (Müller et al., 2025; Liu et al., 2026b; Zhang et al.,

2025c; Li et al., 2026a; Rojas et al., 2025; Yang et al., 2026; Liu et al., 2026a)。其中，离线方法能够利用完整序列提供的全局约束，但通常需要在整段视频上反复优化人体运动、相机轨迹和场景几何，带来较高的推理延迟与计算开销，也难以扩展到不断增长的长视频。统一前馈方法降低了逐序列优化的成本；对于持续视频流，模型还需要仅根据当前与历史观测在线更新重建结果，并保持有界的历史表示规模和稳定的单步计算开销。因此，问题进一步从如何利用完整视频恢复全局关系，转向如何通过持续维护的历史表示实现在线重建。

在线重建。 围绕这一目标，在线重建按照时间顺序处理视频，并持续更新相机、几何与人体估计。传统 SLAM、学习式稠密建图和前馈点图模型分别为增量式相机定位、场景建图和直接三维预测奠定了基础 (Teed & Deng, 2021; Sun et al., 2021a; Wang et al., 2024a; Leroy et al., 2024; Zhang et al., 2025a; Wang et al., 2025a); 近期流式方法进一步通过空间记忆、渐进式配准或递归状态保留历史观测 (Wang & Agapito, 2025; Liu et al., 2025; Wang et al., 2025b)。在人体重建方面，OnlineHMR 研究世界坐标系下的在线人体恢复 (Zhao et al., 2026)，Human3R 则以 CUT3R 的递归重建为基础，将在线恢复扩展到相机、场景和多个人体 (Chen et al., 2026b)。在此基础上，UniCon3R 和 GUSH3R 分别从人体—场景接触与可渲染动态表示等方向扩展统一重建 (Sur et al., 2026; Abe et al., 2026)，其他流式三维方法则进一步研究长期记忆、动态几何和递归状态的稳定更新 (Chen et al., 2025; Wu et al., 2025; Zhuo et al., 2025; Chen et al., 2026a; Zheng et al., 2026; Li et al., 2026b)。然而，现有在线方法主要面向连续拍摄的单目视频，通常依赖相邻帧之间稳定的时间关系和视觉重叠来延续已有重建。多镜头视频中的镜头切换会突然改变相机视角与可见内容，使相邻镜头不再满足这种连续性假设，但不同镜头的重建结果仍需被组织到统一的空间关系中。因此，如何跨越镜头切换维持重建的一致性，构成了在线重建进一步面向多镜头视频时需要解决的问题。

多镜头人体重建。 多镜头人体重建旨在从包含镜头切换的单目视频中恢复空间一致的多人体三维运动，并保持跨镜头的人物身份一致性。早期工作分别研究了影视内容中的人物跟踪与重识别、单人体跨镜头恢复以及演员—环境联合重建 (Pavlakos et al., 2022a;b;c)。HumanMM 通过相机运动估计与序列级运动整合，在多个镜头之间对齐人体朝向和全局轨迹，但主要面向单人体视频 (Zhang et al., 2025b)。与本文任务最接近的 Multi-THuMBS 利用三维场景先验将镜头边界两侧的观测重建到共同空间中，并结合外观、姿态和几何线索完成人物关联，随后通过轨迹平滑与跨相机重投影约束优化全局结果 (On et al., 2026); 该方法将多镜头重建扩展到多人场景，但采用依赖已观测序列的多阶段全局优化。ShowMak3R 同样处理多人物和多镜头内容，但通过逐视频优化人物与场景的神经表示，主要面向可渲染的影视内容重建，而非在线人体运动恢复 (Kim et al., 2025)。此外，跨镜头身份保持也与三维感知跟踪以及基于外观、姿态或关键点的人物重识别相关 (Rajasegaran et al., 2022; He et al., 2021; Yuan et al., 2025; Somers et al., 2024)。这些工作从全局运动恢复、空间对齐和人物关联等角度推进了多镜头人体重建，但多采用镜头边界两侧的联合处理或对完整序列进行逐视频优化，尚未讨论在线递归重建中持续维护的历史信息应当如何跨越镜头边界。Shot3R 面向这一流式设定，将历史信息暂时用于建立镜头间空间关系，但不再将其作为新镜头的递归状态持续传播，从而在顺序处理多镜头视频的同时维持空间与身份一致性。

3 方法

Shot3R 按照时间顺序处理多镜头单目视频，并将相机、可见人体和场景几何重建到统一世界坐标系中。在每个镜头内部，递归重建器持续更新紧凑的历史表示。在镜头切换处，这些历史仍是建立镜头间空间关系所需的有效参照，却不再适合作为新视觉内容继续传播的递归条件。因此，Shot3R 为历史的这两种作用赋予不同的信息生命周期。

如图 2 所示，检测到镜头边界后，同一幅新镜头首帧进入两条互补路径。历史条件对齐路径临时读取先前状态以推断镜头间关系，随后即被丢弃；重新初始化重建路径独立开始新镜头，并拥有唯一向后传播的状态。带类型的对齐表示从当前观测与递归历史中组织边界证据。估计得到的镜头关系、基于几何的人物关联和共享变换随后将重新初始化路径的输出提交到已有世界坐标系。该边界操作只使用当前与历史观测，不修改已经输出的帧，也不执行逐视频优化。

3.1 镜头边界处的递归重建

给定由连续镜头片段组成的单目视频流 $\{I_t\}_{t=1}^T$ ，Shot3R 在时刻 t 仅利用截至当前的观测，在线恢复相机姿态 C_t 、场景几何 P_t^w 与多个可见人体 $\mathcal{H}_t$ 。所有输出均表示在一个统一世界坐




Figure 2: Shot3R 方法概览。历史条件路径临时推断镜头间关系，只有重新初始化路径传播递归状态。基于几何的人物关联延续人物身份，共享变换将新镜头输出置于统一世界坐标系。最右侧面板为示意图。

标系中：该坐标系由首个镜头初始化，并由所有后续镜头及其相机、人体和场景几何共享，而非外部预先指定的绝对坐标系。将历史观测编码为递归状态 S_t ，一般的有状态重建过程可以表示为

$$(y_t, S_t) = f_\theta(I_t, S_{t-1}), \quad y_t = (C_t, P_t^w, \{J_t^i, V_t^i, q_t^i\}_{i=1}^{N_t}), \quad (1)$$

其中， C_t 为 camera-to-world 相机姿态， J_t^i 、 V_t^i 和 q_t^i 分别表示人物 i 的 SMPL-X (Pavlakos et al., 2019) 关节、网格顶点与匿名人物槽位。在实现中，我们使用预训练的 Human3R 递归重建器构造 f_θ ，由其提供镜头内的相机、人体与场景预测 (Chen et al., 2026b)。在连续观测下， S_{t-1} 所承担的空间参照与递归条件两种作用相互兼容；镜头切换则使二者分离。旧状态仍可作为推断新镜头与已有重建之间关系的依据，但其中由上一镜头视角和内容形成的表示，已不再是更新新镜头状态的有效条件。直接传播能够保留空间参照，却可能使这种失配持续影响后续递归；重新初始化能够隔离失配，却同时失去了镜头间的空间关系。

为解决这一冲突，Shot3R 在检测到的镜头边界 b 对同一幅新镜头首帧执行两次互补的在线计算：

$$\begin{aligned} (\tilde{y}_b, \tilde{S}_b) &= f_{\theta, \phi}(I_b, S_{b-1}), & (y_b^r, S_b^r) &= f_\theta(I_b, S_\emptyset), \\ (y_t^r, S_t^r) &= f_\theta(I_t, S_{t-1}^r), & t &> b. \end{aligned} \quad (2)$$

历史条件对齐路径读取 S_{b-1} ，仅用于推断新镜头与已有世界坐标系之间的关系；边界操作完成后，其预测结果和 $\tilde{S}_b$ 均被丢弃。重新初始化重建路径从 $S_\emptyset$ 出发，并以 S_b^r 作为该镜头后续所有帧唯一的递归状态。因此，镜头间关系估计与新镜头状态传播具有彼此独立的信息路径。

3.2 历史条件镜头对齐

历史条件路径需要从新镜头首帧 I_b 与先前状态 S_{b-1} 的交互中估计镜头间空间关系。用于连续重建的递归表示同时包含图像内容、相机运动、人体信息与历史上下文，而镜头边界处的关系推断需要区分这些信息所承担的不同作用。为避免过早将全部证据汇聚成单一校正向量，Shot3R 显式构造三种带类型的对齐表示，分别描述语义对应、相机潜变量变化和累积的时间上下文。

令 c_b 表示从当前图像、相机和人体 token 中汇聚的观测证据， m_{b-1} 表示从递归状态与相机记忆中提取的历史证据。三种带类型表示定义为

$$\begin{aligned} z_b^{\text{sem}} &= \alpha_b c_b + (1 - \alpha_b) m_{b-1}, & z_b^{\text{cam}} &= \text{MLP}_{\text{cam}}[p_b, p_{b-1}, \Delta p_b, m_{b-1}], \\ z_b^{\text{temp}} &= \text{MLP}_{\text{temp}}[\bar{z}_{b-1}, \delta_{b-1}, g_{b-1}], & z_b^{\text{align}} &= [z_b^{\text{sem}}, z_b^{\text{cam}}, z_b^{\text{temp}}]. \end{aligned} \quad (3)$$

其中, α_b 自适应调节当前语义证据与历史上下文的贡献; p_b 和 p_{b-1} 为边界两侧的相机 token, $\Delta p_b = p_b - p_{b-1}$ 表示其潜变量变化; $\tilde{z}_{b-1}$ 、 δ_{b-1} 和 g_{b-1} 分别表示此前的对齐摘要、相机潜变量残差及其门控强度。三种表示并非相互独立的重建模块, 而是对异质边界信息进行分类型组织, 使不同证据在进入解码器时保持来源可辨。

加入类型嵌入后, z_b^{align} 被插入原生相机 token 之后, 并与图像、相机和人体表示共同通过冻结的递归主干。解码后的边界表示产生门控的相机与人体潜变量残差。前者在原有相机预测头输出临时相机 C_b 之前更新相机表示; 后者将人物平移约束纳入同一边界推断过程。所有带类型表示与潜变量更新仅存在于对齐路径中, 不会写入新镜头随后传播的状态。汇聚与残差分支的完整定义见英文补充材料。

我们同时使用镜头切换与连续四帧序列训练对齐表示。镜头切换样本由两个相机的 $A(t)$, $A(t+1)$, $B(t+2)$, $B(t+3)$ 构成, 用于监督视角切换前后的变化; 连续样本由同一相机的连续四帧构成, 用于维持连续输入下的原有重建行为。




Figure 3: 历史条件镜头对齐。带类型表示组织当前与历史证据; 门控潜变量更新仅存在于临时路径。

对齐训练目标联合监督相机平移、相机旋转、人体平移、残差门控以及校正有效性:

$$\mathcal{L}_{\text{align}} = \mathcal{L}_t + 5\mathcal{L}_R + 10\mathcal{L}_h + 0.05(\mathcal{L}_g + \mathcal{L}_{\text{imp}}) + 10^{-5}(\mathcal{R}_{\text{cam}} + \mathcal{R}_{\text{human}}), \quad (4)$$

其中, $\mathcal{L}_t$ 与 $\mathcal{L}_h$ 为相机和人体平移的 Smooth-L1 损失, $\mathcal{L}_R$ 为四元数测地距离。令 e 和 e^{raw} 分别表示归一化后的校正相机误差与未校正误差, 则门控与有效性约束为 $\mathcal{L}_g = \text{BCE}(g, \text{clip}(e^{\text{raw}}, 0, 1))$ 和 $\mathcal{L}_{\text{imp}} = [e - e^{\text{raw}}]_+$, 其余两项用于正则化相机与人体潜变量更新。镜头切换改变的是历史信息与当前观测之间的关系, 而不是镜头内的重建目标。因此, 我们仅优化带类型表示、相机与人体潜变量残差分支, 以及预测头中的低秩适配参数 (Hu et al., 2022); 图像编码器、递归主干、基础预测头和 Multi-HMR 组件 (Baradel et al., 2024) 均保持冻结。

3.3 跨镜头空间与身份一致性

重新初始化路径隔离了不兼容历史对新镜头递归过程的影响, 但其预测位于独立初始化的局部坐标系中。跨镜头关系只有在不重新引入先前递归状态的情况下作用于这些预测, 才能将其提交到统一世界坐标系。为此, Shot3R 仅保留边界时刻推断出的相机关系并将其作用于重新初始化路径的输出; 临时对齐状态没有进入后续递归的通路。由于两条路径处理同一幅图像, 其相对相机姿态反映了历史条件所确定的空间关系。令 C_b^r 表示重新初始化路径预测的 camera-to-world 姿态, $\tilde{C}_b$ 表示已经表达在累计统一世界坐标系中的临时对齐路径相机姿态, 则新镜头局部坐标系的初始映射为

$$T_b^{\text{align}} = \tilde{C}_b(C_b^r)^{-1}. \quad (5)$$

该变换满足 $T_b^{\text{align}} C_b^r = \tilde{C}_b$, 因此可以将重新初始化路径的相机和人体预测映射到已有坐标系。对于后续镜头切换, $\tilde{C}_b$ 已包含此前累计的镜头间变换。需要强调的是, T_b^{align} 来自边界处当前观测与递归历史的特征交互, 而不是在两个镜头完成重建后对其输出执行事后配准。

相机关系本身不能确定人物对应。完成初始空间映射后, Shot3R 使用预测的人体根节点位置、躯干朝向和去除根节点平移后的关节结构建立一对一关联。对于线索 $a \in \{\text{root}, \text{torso}, \text{joint}\}$, 我们分别归一化其成代价矩阵, 并构造联合代价:

$$\hat{d}_{ij}^a = \frac{d_{ij}^a}{\max(\text{median}_{u,v} d_{uv}^a, \epsilon)}, \quad d_{ij} = \hat{d}_{ij}^{\text{root}} + \hat{d}_{ij}^{\text{torso}} + \hat{d}_{ij}^{\text{joint}}. \quad (6)$$

其中，根节点项为欧氏距离，躯干项为角距离，关节项为去除根节点平移后对应关节欧氏距离的均值。通过 Hungarian assignment (Munkres, 1957) 得到匹配集合 $\mathcal{M}_b$ 。匹配不使用身份标注、外部相机标定或后续帧。匹配人物继承上一镜头的匿名身份，未匹配的新镜头人物槽位获得新的身份。该置换只在新镜头首帧建立一次，后续帧保留重新初始化递归所维持的原始人物槽位。

初始相机映射确定新镜头的朝向及其与已有坐标系的主要关系，匹配人物则为剩余的共享平移提供直接约束。令 r_{b-1}^i 表示上一镜头末帧中人物 i 的预测骨盆中心， $\bar{r}_b^j$ 表示完成初始映射后新镜头首帧中人物 j 的骨盆中心，我们估计

$$\Delta_b = \lambda \operatorname{median}_{(i,j) \in \mathcal{M}_b} (r_{b-1}^i - \bar{r}_b^j), \quad \lambda = 0.5, \quad (7)$$

其中，中位数沿三个空间坐标分别计算，固定的 λ 在所有数据集上保持不变。当边界处没有有效匹配时，不施加该平移，仅保留相机关系给出的初始映射。令 $T_b^\Delta = \begin{bmatrix} I_3 & \Delta_b \\ \mathbf{0}^\top & 1 \end{bmatrix}$ 且 $T_b = T_b^\Delta T_b^{\text{align}}$ ，则对于 $t \geq b$ ，最终提交的输出为

$$\begin{aligned} C_t' &= T_b C_t^r, & J_t^i &= T_b J_t^{r,i}, & V_t^i &= T_b V_t^{r,i}, \\ P_t'^w &= C_t' P_t^{r,c} = T_b P_t^{r,w}, & q_t^i &= \pi_b(q_t^{r,i}), & S_t' &= S_t^r. \end{aligned} \quad (8)$$

其中， π_b 表示边界处得到的身份映射，三维点均使用齐次坐标。相机局部场景点图 $P_t^{r,c}$ 保持不变，其世界坐标表示由变换后的相机姿态一致地确定。同一个世界变换作用于相机和全部人体，从而保持二者的相对几何；保留 S_t^r 则确保只有重新初始化状态进入未来的重建过程。变换被缓存，并在后续帧被依次处理时作用于其输出。整个过程不访问后续帧、不执行序列级优化，也不修改已经输出的历史结果。

4 实验

4.1 实验设置

对比方法。 我们采用公开发布的 Human3R 检查点作为主要受控基线。Human3R 和 Shot3R 接收完全相同、按时间排序的 RGB 帧，并使用相同的预处理与评测流程；二者的主要区别在于，Human3R 连续传播递归状态，而 Shot3R 在检测到镜头切换后，通过历史条件对齐与重新初始化的递归过程处理镜头边界。我们还评测 OnlineHMR、TRACE、PromptHMR 和 JOSH 的官方实现，并将 TRAM 纳入统一计时 (Zhao et al., 2026; Sun et al., 2023; Wang et al., 2025c; Liu et al., 2026b; Wang et al., 2024b)。主表按照时间信息访问方式对这些方法进行分组，并标明其是否显式处理镜头切换；预处理与输出范围见英文补充材料。HumanMM 和 Multi-THuMBS 作为相关工作背景予以讨论，但由于其完整代码、模型权重和评测配置尚未公开，不纳入定量比较。

数据集与评价指标。 我们基于 EgoBody、EgoHumans 和 Harmony4D 构建顺序多镜头输入 (Zhang et al., 2022; Khirrodar et al., 2023; 2024)。具体而言，我们将这些数据集中的同步采集转换为依次输入、而非同时输入的单目镜头，共得到 129、90 和 88 个固定评测样例。EgoBody 用于对镜头边界机制进行受控分析，EgoHumans 包含显著的视角变化，Harmony4D 则提供密集多人交互和重复镜头切换评测。W-MPIPE (W) 使用最早的有效观测确定并固定 Sim(3) 对齐，因此对镜头间位置偏移较为敏感；WA-MPIPE (WA) 则利用全部有效观测进行对齐。我们还报告相机轨迹误差、衡量跨镜头身份连续性的 IDF1 (Ristani et al., 2016)，以及用于反映缺失预测的 Coverage。完整的指标定义与聚合方式见英文补充材料。

实现细节。 Shot3R 仅在 AvatarReX 和 THuman 上训练，两者均不属于本文的评测基准。我们选择性地优化 19.62M 个参数，占完整 1.208B 参数模型的 1.63%。这些可训练参数包括镜头边界对齐组件和低秩适配参数，其余原始预训练主干参数保持冻结。该设计将模型适配集中于镜头边界处当前观测与递归历史之间的交互，同时保留预训练模型已有的镜头内重建先验。所有评测基准均使用同一检查点和推理配置，不进行针对数据集或单个视频的优化。训练数据组成、优化配置、参数构成、硬件环境和收敛曲线见英文补充材料。




Figure 4: 跨镜头切换的关键定性比较。每一行首先展示切换前后的输入，随后依次给出 OnlineHMR、JOSH、Human3R 和 Shot3R 的结果。视角变化从上到下为 134.36°、149.85° 和 176.75°。Shot3R 保持更连贯的相机—人体布局；方法能够输出场景几何时一并显示。完整七方法版本见英文补充材料。

Table 1: EgoBody 与 EgoHumans 多镜头多人体重建协议上的比较。

类别	方法	切换处理	EgoBody ($N = 129$)					EgoHumans ($N = 90$)				
			W ↓	WA ↓	ATE ↓	IDF1 ↑	覆盖率 ↑	W ↓	WA ↓	ATE ↓	IDF1 ↑	覆盖率 ↑
离线	PromptHMR (SPEC)	×	741.4 ⁶⁴	336.1 ⁸⁷	—	0.195	0.202	1193.3 ¹⁷	487.7 ²⁵	—	0.061	0.062
	JOSH	×	399.6 ¹²⁷	322.9 ¹²⁷	0.087 ¹²⁷	0.973	0.980	1410.7 ⁷⁷	481.3 ⁷⁷	1.755 ⁸⁷	0.616	0.686
半在线	OnlineHMR	×	961.2 ⁹⁷	418.1 ⁹⁷	0.259 ¹²⁹	0.375	0.424	1311.7 ⁵⁰	405.5 ⁵⁰	3.869 ⁸⁷	0.142	0.211
在线	TRACE	×	576.4 ²²	276.4 ³⁵	—	0.036	0.035	2464.6 ⁴³	749.5 ⁵⁹	—	0.070	0.072
	Human3R	×	321.1	233.4	0.124	0.870	0.981	1005.1	365.7	1.673	0.471	0.639
	Shot3R	✓	258.8	201.7	0.016	0.985	0.981	866.8	336.9	1.423	0.571	0.616

“切换处理”表示方法是否显式处理镜头切换。W/WA 单位为 mm，ATE 单位为 m (EgoBody 使用 Sim(3)，EgoHumans 使用 SE(3))。上标表示条件几何指标的可评测视频数；IDF1 与 Coverage 使用完整预定义协议。不同有效样本集合上的条件几何均值不能构成统一排名。

4.2 多镜头多人体重建

表 1 给出 EgoBody 和 EgoHumans 的结果，Harmony4D 的完整比较见英文补充材料。在与 Human3R 的主要受控比较中，Shot3R 在三个数据集上均改善了 WA、相机误差和 IDF1；W 在 EgoBody 和 EgoHumans 上得到改善，在 Harmony4D 上略有增加。在 EgoBody 上，W/WA 从 321.1/233.4 mm 降至 258.8/201.7 mm，ATE 从 0.124 m 降至 0.016 m，IDF1 从 0.870 提升至 0.985，Coverage 同为 0.981。局部姿态与人体网格精度基本保持不变，说明主要收益来自统一坐标系中的空间定位、相机估计和身份连续性，而非重新学习镜头内部的人体重建。公开系统比较提供了互补证据：在双方均可评测的相同输入上，Shot3R 相对 OnlineHMR 具有更低的人体与相机误差，并在全部视频上获得更高的 IDF1 和 Coverage；在与离线 JOSH 均可评测的样例上，Shot3R 在三个数据集上的 W、WA 和 ATE 均更低，且不访问未来帧。TRACE 与 PromptHMR 仅能在部分 EgoBody 输入上返回可评测的几何结果，因此其条件误差需要结合有效样本数理解；完整的配对比较与失败记录见英文补充材料。

随着镜头间视角差增大，Shot3R 的优势更加明显。按数据集等权汇总时，Shot3R 在全部视角下将 W-MPIPE 降低 9.5%，在预定义大视角子集上降低 19.1%。EgoBody 极端视角子集中，W-MPIPE 降低 29.9%，IDF1 从 0.758 提升至 0.983。图 4 展示了 134.36°、149.85° 和 176.75° 的镜头切换：尽管视角和人体外观显著变化，Shot3R 仍能维持更连贯的相机—人体布局。图 5 与英文补充材料给出了完整的视角区间结果与连续角度分析。

4.3 分析与消融实验

我们首先使用同一原始 Human3R 检查点，在 90 个由静态物理相机采集的 EgoHumans 样例中处理完全相同的切换后 RGB 帧，以单独检验旧状态延续的影响；两个控制均不使用任何




Figure 5: **EgoHumans** 中的视角响应。曲线给出四个固定视角区间内的 W-MPJPE 和 IDF1 绝对值，阴影为以 capture 为单位 bootstrap 得到的 95% 置信区间。Shot3R 在全部区间均提高 IDF1，并在 130° 和 177° 时明显降低 W-MPJPE。




Figure 6: 跨镜头延续旧状态会导致新镜头内部的相机漂移。在静态相机采集中，相同的未修改 Human3R 检查点处理完全相同的新镜头 RGB，且不使用 Shot3R 组件。首个预测锚定消除固定坐标变换后，旧状态延续仍产生漂移，而重新初始化保持稳定。

Shot3R 组件。两条相机轨迹均锚定到新镜头的首个预测，以消除固定坐标变换。后续 16 帧中，延续旧状态产生 1.124 m/14.58° 的平移/旋转漂移，而重新初始化后仅为 0.026 m/0.20°，且后者在全部 27 个 capture 上均更低。因此，旧状态延续引起的是新镜头内随时间变化的漂移，而不只是一个固定坐标偏移。置信区间、不同测量窗口及配对检验见英文补充材料。

表 2 进一步区分了不同的失效模式。仅重新初始化状态会失去镜头间空间关系，W/WA 达到 752.6/589.4 mm，ATE 为 1.141 m。加入对齐后，延续状态的 W/WA 低于重新初始化状态 (293.3/227.3 mm 对 352.8/267.7 mm)，但重新初始化将 ATE 从 0.082 m 降至 0.017 m。这说明对齐用于恢复镜头之间的空间关系，重新初始化则用于稳定新镜头内部的递归过程；任何一项都无法单独解决两种失效。完整 Shot3R 进一步通过人物关联支持身份连续性，并使用相机—人体共享变换，最终达到 258.8/201.7 mm W/WA、0.016 m ATE 和 0.985 IDF1。上述结果来自完整设计的共同作用，不能归因于任一单独组件，并支持将镜头间对齐与递归状态传播视为两个独立决策。

几何配准对照实验。 我们进一步检验，对每个镜头独立重建后再进行显式几何拟合，是否能够恢复相同的跨镜头结果。所有对照均从完全相同的逐镜头状态重置预测出发，分别估计共享骨盆平移、基于人体关节的鲁棒 SE(3)，或者利用两个完整镜头场景点云估计离线 FPFH/RANSAC+ICP 变换。三种几何对照均获得标注镜头边界且只使用模型预测，Shot3R 则仍使用在线边界检测。如表 3 所示，Shot3R 在两个完整测试集上均取得最低的 W 和 ATE，以及最高的 IDF1。人体关节 SE(3) 是最强的几何对照，其 W 已接近 Shot3R，但身份一致性更低，并在 17.8% 的 EgoHumans 样例上拟合失败。这表明，人体引导的几何拟合能够恢复较多空间关系，而 Shot3R 无需单独拟合阶段即可获得更均衡的人体定位、相机估计与身份一致性。完整 WA/Coverage、配对置信区间、固定视角分层和失败分析见英文补充材料。

补充分析进一步考察人物关联、重复镜头切换和运行效率。在 Harmony4D 上，在骨盆位置基础上加入躯干朝向与去根节点后的关节结构，使身份延续率从 78.41% 提升至 80.68%，IDF1 从 0.620 提升至 0.635，说明这些预测几何线索具有互补作用。小规模三镜头受控实验表明，同一边界操作可以重复执行，但这一结果并不意味着长序列中不存在累积误差。在线检测器在全部主要协议流中均识别出标注边界。在单张 NVIDIA L20 上的标准化重建计时中，Shot3R 与 Human3R 分别达到 3.106 和 3.224 FPS，具有相近的吞吐量。完整人物关联消融、镜头切换次数分析以及七种方法的完整系统计时见英文补充材料。

Table 2: EgoBody 上的对齐—状态传播 2×2 受控实验及完整 Shot3R。

设置	边界信号	镜头切换操作			EgoBody 指标			
		传播	状态	人物关联	W (mm) ↓	WA (mm) ↓	ATE (m) ↓	IDF1 ↑
Human3R	—	×	延续	×	321.1	233.4	0.124	0.870
状态重新初始化	标注	×	重新初始化	×	752.6	589.4	1.141	0.834
对齐 + 延续状态	标注	✓	延续	×	293.3	227.3	0.082	0.868
对齐 + 重新初始化状态	标注	✓	重新初始化	×	352.8	267.7	0.017	0.834
Shot3R	检测	✓	重新初始化	✓	258.8	201.7	0.016	0.985

三个受控设置使用标注边界，Human3R 不接收边界信号。两个包含对齐的受控设置均关闭显式人物关联和人物引导共享平移，因此二者只改变对齐后传播的状态。

Table 3: 完整 EgoBody 与 EgoHumans 测试集上的几何配准对照。W 的单位为毫米，ATE 的单位为米。Fit 表示 EgoHumans 上独立几何拟合的成功率；Shot3R 不包含该阶段。

方法	信息访问方式	EgoBody ($N = 129$)			EgoHumans ($N = 90$)			
		W ↓	ATE ↓	IDF1 ↑	W ↓	ATE ↓	IDF1 ↑	拟合成功率 ↑
Human3R 逐镜头重置	独立镜头	752.6	1.141	0.834	1248.1	4.411	0.455	—
+ 骨盆平移	边界时刻	500.2	0.068	0.896	1242.1	3.326	0.506	100.0%
+ 人体关节 SE(3)	边界时刻	261.5	0.019	0.896	897.0	1.731	0.510	82.2%
+ 场景 FPFH+ICP	离线完整镜头	733.2	0.020	0.834	1372.8	3.847	0.455	41.1%
Shot3R	流式	258.8	0.016	0.985	866.8	1.423	0.571	—

传统对照获得标注镜头边界，且估计变换时均不使用真实值。拟合失败的样例严格回退为逐镜头重置结果，并保留在固定评测分母中。EgoBody 上的几何拟合均成功。

5 结论

本文研究跨镜头切换的流式重建问题，其中递归历史具有相互冲突的作用：它为建立相邻镜头之间的关系提供必要参照，但持续传播同一状态又可能在新镜头内引起随时间变化的漂移。我们的核心观察是，历史应被临时读取以完成镜头间对齐，而不应作为新镜头的递归状态继续传播。基于这一观察，Shot3R 通过切换前历史推断镜头间关系，同时仅允许独立重新初始化的状态驱动后续重建。它将各镜头中的相机、人体和场景几何表示到统一世界坐标系，并维持跨镜头人物身份，同时按照输入顺序处理每一帧，无需访问未来帧或进行逐视频优化。三个多人体基准上的实验表明，Shot3R 能够持续改善统一坐标系下的人体重建、相机轨迹估计和人物身份关联，并在大幅视角变化下取得最明显的收益。如何在包含复杂剪辑、人物反复进出以及快速视觉变化的长视频中保持稳定重建，仍是值得进一步研究的问题。

AI 使用声明

本文在规划、文字编辑、分析支持、代码框架搭建，以及可编辑矢量图的布局和标注过程中使用了语言模型辅助。语言模型没有合成评测输入、重建结果面板、真值或数值测量。作者检查了底层记录，并对每项实验协议、结果、图、引用和论断负责。

伦理声明

本文使用的人体采集数据集均为公开数据或获得研究许可的数据，并遵循数据提供方的知情同意、访问和科研使用条件。我们不推断参与者身份，不跨数据集关联参与者，也不将这些材料用于监控。受限图像、标注和模型权重保存在访问受控的存储中，并在许可禁止时不进行重新分发。

可复现性声明

我们保留固定的评测定义、评测代码、逐样本记录、方法—代码映射、流式输入检查、使用相同权重的状态隔离实验、对齐—状态传播受控实验、按视角聚类的统计、人物关联线索消融和重复镜头切换实验。论文表格由带有来源哈希的机器可读汇总生成。完整复现还需要获得许可的数据和检查点；在许可允许的范围内，发布材料将包含代码、协议清单、汇总测量和不含身份信息的样本标识符。

参考文献

- Keito Abe, Kaede Shiohara, Takashi Otonari, and Toshihiko Yamasaki. GUSH3R: Everyone everywhere all at once as gaussians, 2026. URL <https://arxiv.org/abs/2607.05243>.
- Fabien Baradel, Matthieu Armando, Salma Galaaoui, Romain Brégier, Philippe Weinzaepfel, Grégory Rogez, and Thomas Lucas. Multi-HMR: Multi-person whole-body human mesh recovery in a single shot. In *European Conference on Computer Vision*, 2024.
- Xingyu Chen, Yue Chen, Yuliang Xiu, Andreas Geiger, and Anpei Chen. TTT3R: 3d reconstruction as test-time training. In *International Conference on Learning Representations*, 2026a. URL <https://arxiv.org/abs/2509.26645>.
- Yue Chen, Xingyu Chen, Yuxuan Xue, Anpei Chen, Yuliang Xiu, and Gerard Pons-Moll. Human3R: Everyone everywhere all at once. In *International Conference on Learning Representations*, 2026b. URL <https://arxiv.org/abs/2510.06219>.
- Zhuoguang Chen, Minghui Qin, Tianyuan Yuan, Zhe Liu, and Hang Zhao. Long3R: Long sequence streaming 3d reconstruction, 2025. URL <https://arxiv.org/abs/2507.18255>.
- Shubham Goel, Georgios Pavlakos, Jathushan Rajasegaran, Angjoo Kanazawa, and Jitendra Malik. Humans in 4d: Reconstructing and tracking humans with transformers. In *IEEE/CVF International Conference on Computer Vision*, pp. 14783–14794, 2023.
- Shuting He, Hao Luo, Pichao Wang, Fan Wang, Hao Li, and Wei Jiang. TransReID: Transformer-based object re-identification. In *IEEE/CVF International Conference on Computer Vision*, 2021. doi: 10.1109/ICCV48922.2021.01474.
- Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022.
- Angjoo Kanazawa, Michael J. Black, David W. Jacobs, and Jitendra Malik. End-to-end recovery of human shape and pose. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 7122–7131, 2018. doi: 10.1109/CVPR.2018.00744.
- Rawal Khirodkar, Aayush Bansal, Lingni Ma, Richard Newcombe, Minh Vo, and Kris Kitani. Ego-Humans: An egocentric 3d multi-human benchmark. In *IEEE/CVF International Conference on Computer Vision*, 2023. URL <https://arxiv.org/abs/2305.16487>.
- Rawal Khirodkar, Jyun-Ting Song, Jinkun Cao, Zhengyi Luo, and Kris Kitani. Harmony4D: A video dataset for in-the-wild close human interactions. In *Advances in Neural Information Processing Systems*, 2024. URL <https://arxiv.org/abs/2410.20294>.
- Sangmin Kim, Seunguk Do, and Jaesik Park. ShowMak3r: Compositional tv show reconstruction. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. URL <https://arxiv.org/abs/2504.19584>.
- Muhammed Kocabas, Nikos Athanasiou, and Michael J. Black. VIBE: Video inference for human body pose and shape estimation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020. URL <https://arxiv.org/abs/1912.05656>.
- Muhammed Kocabas, Ye Yuan, Pavlo Molchanov, Yunrong Guo, Michael J. Black, Otmar Hilliges, Jan Kautz, and Umar Iqbal. PACE: Human and camera motion estimation from in-the-wild videos. In *International Conference on 3D Vision*, pp. 397–408, 2024.
- Vincent Leroy, Yohann Cabon, and Jerome Revaud. Grounding image matching in 3d with MAST3R. In *European Conference on Computer Vision*, 2024. doi: 10.1007/978-3-031-73220-1_5.
- Jiefeng Li, Ye Yuan, Davis Rempe, Haotian Zhang, Pavlo Molchanov, Cewu Lu, Jan Kautz, and Umar Iqbal. COIN: Control-inpainting diffusion prior for human and camera motion estimation. In *European Conference on Computer Vision*, pp. 426–446, 2024. doi: 10.1007/978-3-031-72640-8_24.

- Mengfei Li, Peng Li, Zheng Zhang, Jiahao Lu, Chengfeng Zhao, Wei Xue, Qifeng Liu, Sida Peng, Wenxiao Zhang, Wenhan Luo, Yuan Liu, and Yike Guo. UniSH: Unifying scene and human reconstruction in a feed-forward pass. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026a. URL <https://arxiv.org/abs/2601.01222>.
- Xinze Li, Yiyuan Wang, Pengxu Chen, Wentao Fan, Weifeng Su, Weisi Lin, and Wentao Cheng. ReCal3R: Reliability-calibrated learning rates for streaming 3d reconstruction, 2026b. URL <https://arxiv.org/abs/2607.05356>.
- Jinpeng Liu, Yukang Xu, Yutong Li, and Xingyu Liu. TROPHIES: Temporal reconstruction of places, humans, and cameras from multi-view videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 21154–21164, 2026a. URL <https://arxiv.org/abs/2606.02350>.
- Yuzheng Liu, Siyan Dong, Shuzhe Wang, Yingda Yin, Yanchao Yang, Qingnan Fan, and Baoquan Chen. SLAM3R: Real-time dense scene reconstruction from monocular RGB videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. doi: 10.1109/CVPR52734.2025.01552.
- Zhizheng Liu, Joe Lin, Wayne Wu, and Bolei Zhou. Joint optimization for 4d human–scene reconstruction in the wild. In *International Conference on Learning Representations*, 2026b. URL <https://arxiv.org/abs/2501.02158>.
- Lea Müller, Hongsuk Choi, Anthony Zhang, Brent Yi, Jitendra Malik, and Angjoo Kanazawa. Reconstructing people, places, and cameras. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 21948–21958, 2025.
- James Munkres. Algorithms for the assignment and transportation problems. *Journal of the Society for Industrial and Applied Mathematics*, 5(1):32–38, 1957.
- Jeongwan On, Muhammad Salman Ali, Muneeb A. Khan, Sunwoo Park, Inwoong Moon, Hyung Jin Chang, Jaekwang Kim, Seong Jong Ha, and Seungryul Baek. Multi-THuMBS: Multi-person tracking of 3d human meshes beyond video shots, 2026. URL <https://arxiv.org/abs/2607.01626>.
- Priyanka Patel and Michael J. Black. CameraHMR: Aligning people with perspective. In *International Conference on 3D Vision*, 2025. doi: 10.1109/3DV66043.2025.00146.
- Georgios Pavlakos, Vasileios Choutas, Nima Ghorbani, Timo Bolkart, Ahmed A. A. Osman, Dimitrios Tzionas, and Michael J. Black. Expressive body capture: 3d hands, face, and body from a single image. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019. URL <https://arxiv.org/abs/1904.05866>.
- Georgios Pavlakos, Angjoo Kanazawa, Jitendra Malik, Michael J. Black, and Kostas Daniilidis. Multi-shot person tracking and re-identification in TV series. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022a.
- Georgios Pavlakos, Jitendra Malik, and Angjoo Kanazawa. Human mesh recovery from multiple shots. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022b. URL <https://arxiv.org/abs/2012.09843>.
- Georgios Pavlakos, Ethan Weber, Matthew Tancik, and Angjoo Kanazawa. The one where they reconstructed 3d humans and environments in TV shows. In *European Conference on Computer Vision*, pp. 732–749, 2022c.
- Jathushan Rajasegaran, Georgios Pavlakos, Angjoo Kanazawa, and Jitendra Malik. Tracking people by predicting 3d appearance, location and pose. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022. doi: 10.1109/CVPR52688.2022.00276.
- Ergys Ristani, Francesco Solera, Roger Zou, Rita Cucchiara, and Carlo Tomasi. Performance measures and a data set for multi-target, multi-camera tracking. In *European Conference on Computer Vision Workshops*, 2016.

- Sara Rojas, Matthieu Armando, Bernard Ghanem, Philippe Weinzaepfel, Vincent Leroy, and Gregory Rogez. HAMSt3R: Human-aware multi-view stereo 3d reconstruction. In *IEEE/CVF International Conference on Computer Vision*, 2025. doi: 10.1109/ICCV51701.2025.00478.
- Zehong Shen, Huaijin Pi, Yan Xia, Zhi Cen, Sida Peng, Zechen Hu, Hujun Bao, Ruizhen Hu, and Xiaowei Zhou. World-grounded human motion recovery via gravity-view coordinates, 2024. URL <https://arxiv.org/abs/2409.06662>.
- Soyong Shin, Juyong Kim, Eni Halilaj, and Michael J. Black. WHAM: Reconstructing world-grounded humans with accurate 3d motion. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024. URL <https://arxiv.org/abs/2312.07531>.
- Vladimir Somers, Christophe De Vleeschouwer, and Alexandre Alahi. Keypoint promptable re-identification. In *European Conference on Computer Vision*, 2024.
- Jiaming Sun, Yiming Xie, Linghao Chen, Xiaowei Zhou, and Hujun Bao. NeuralRecon: Real-time coherent 3d reconstruction from monocular video. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 15598–15607, 2021a.
- Qingping Sun, Yanjun Wang, Ailing Zeng, Wanqi Yin, Chen Wei, Wenjia Wang, Haiyi Mei, Chi-Sing Leung, Lei Yang, Ziwei Liu, and Zhongang Cai. AiOS: All-in-one-stage expressive human pose and shape estimation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024. doi: 10.1109/CVPR52733.2024.00180.
- Yu Sun, Qian Bao, Wu Liu, Yili Fu, Michael J. Black, and Tao Mei. Monocular, one-stage, regression of multiple 3d people. In *IEEE/CVF International Conference on Computer Vision*, pp. 11179–11188, 2021b.
- Yu Sun, Wu Liu, Qian Bao, Yili Fu, Tao Mei, and Michael J. Black. Putting people in their place: Monocular regression of 3d people in depth. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 13243–13252, 2022.
- Yu Sun, Qian Bao, Wu Liu, Tao Mei, and Michael J. Black. TRACE: 5d temporal regression of avatars with dynamic cameras in 3d environments. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023. URL <https://arxiv.org/abs/2306.02850>.
- Tanuj Sur, Shashank Tripathi, Nikos Athanasiou, Ha Linh Nguyen, Kai Xu, Michael J. Black, and Angela Yao. UniCon3R: Unified contact-aware 4d human-scene reconstruction from monocular video, 2026. URL <https://arxiv.org/abs/2604.19923>.
- Zachary Teed and Jia Deng. DROID-SLAM: Deep visual SLAM for monocular, stereo, and RGB-D cameras. In *Advances in Neural Information Processing Systems*, volume 34, pp. 16558–16569, 2021.
- Hengyi Wang and Lourdes Agapito. 3d reconstruction with spatial memory. In *International Conference on 3D Vision*, 2025. doi: 10.1109/3DV66043.2025.00013.
- Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual geometry grounded transformer. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025a.
- Qianqian Wang, Yifei Zhang, Aleksander Holynski, Alexei A. Efros, and Angjoo Kanazawa. Continuous 3d perception model with persistent state, 2025b. URL <https://arxiv.org/abs/2501.12387>.
- Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. DUST3R: Geometric 3d vision made easy. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024a. URL <https://arxiv.org/abs/2312.14132>.
- Yufu Wang, Ziyun Wang, Lingjie Liu, and Kostas Daniilidis. TRAM: Global trajectory and motion of 3d humans from in-the-wild videos. In *European Conference on Computer Vision*, 2024b. URL <https://arxiv.org/abs/2403.17346>.

- Yufu Wang, Yu Sun, Priyanka Patel, Kostas Daniilidis, Michael J. Black, and Muhammed Kocabas. PromptHMR: Promptable human mesh recovery. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025c. URL <https://arxiv.org/abs/2504.06397>.
- Yuqi Wu, Wenzhao Zheng, Jie Zhou, and Jiwen Lu. Point3R: Streaming 3d reconstruction with explicit spatial pointer memory, 2025. URL <https://arxiv.org/abs/2507.02863>.
- Fengyuan Yang, Kerui Gu, Ha Linh Nguyen, Tze Ho Elden Tse, and Angela Yao. Humans as checkerboards: Calibrating camera motion scale for world-coordinate human mesh recovery. In *IEEE/CVF International Conference on Computer Vision*, 2025. doi: 10.1109/ICCV51701.2025.00573.
- Yuanwang Yang, Buzhen Huang, Zongxuan Ren, Jing Huang, and Kun Li. Feed-forward multi-view multi-person reconstruction with contrastive human-aware 3d representation. *International Journal of Computer Vision*, 134(9):414, 2026. doi: 10.1007/s11263-026-03000-0. URL <https://doi.org/10.1007/s11263-026-03000-0>.
- Vickie Ye, Georgios Pavlakos, Jitendra Malik, and Angjoo Kanazawa. Decoupling human and camera motion from videos in the wild, 2023. URL <https://arxiv.org/abs/2302.12827>.
- Wanqi Yin, Zhongang Cai, Ruishi Wang, Fanzhou Wang, Chen Wei, Haiyi Mei, Weiye Xiao, Zhitao Yang, Qingping Sun, Atsushi Yamashita, Ziwei Liu, and Lei Yang. WHAC: World-grounded humans and cameras, 2024. URL <https://arxiv.org/abs/2403.12959>.
- Chao Yuan, Guiwei Zhang, Changxiao Ma, Tianyi Zhang, and Guanglin Niu. From poses to identity: Training-free person re-identification via feature centralization. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. doi: 10.1109/CVPR52734.2025.02273.
- Ye Yuan, Umar Iqbal, Pavlo Molchanov, Kris Kitani, and Jan Kautz. GLAMR: Global occlusion-aware human mesh recovery with dynamic cameras. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022. URL <https://arxiv.org/abs/2112.01524>.
- Junyi Zhang, Charles Herrmann, Junhwa Hur, Varun Jampani, Trevor Darrell, Forrester Cole, Deqing Sun, and Ming-Hsuan Yang. MonST3R: A simple approach for estimating geometry in the presence of motion. In *International Conference on Learning Representations*, 2025a.
- Siwei Zhang, Qianli Ma, Yan Zhang, Zhiyin Qian, Taein Kwon, Marc Pollefeys, Federica Bogo, and Siyu Tang. EgoBody: Human body shape and motion of interacting people from head-mounted devices. In *European Conference on Computer Vision*, 2022. URL <https://arxiv.org/abs/2112.07642>.
- Yuhong Zhang, Guanlin Wu, Ling-Hao Chen, Zhuokai Zhao, Jing Lin, Xiaoke Jiang, Jiamin Wu, Zhuoheng Li, Hao Frank Yang, Haoqian Wang, and Lei Zhang. HumanMM: Global human motion recovery from multi-shot videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025b. URL <https://arxiv.org/abs/2503.07597>.
- Zetong Zhang, Manuel Kaufmann, Lixin Xue, Jie Song, and Martin R. Oswald. ODHRS: Online dense 3d reconstruction of humans and scenes from monocular videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025c. doi: 10.1109/CVPR52734.2025.02033.
- Yiwen Zhao, Ce Zheng, Yufu Wang, Hsueh-Han Daniel Yang, Liting Wen, and Laszlo A. Jeni. OnlineHMR: Video-based online world-grounded human mesh recovery. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026. URL <https://arxiv.org/abs/2603.17355>.
- Zhijie Zheng, Xinhao Xiang, and Jiawei Zhang. TTSA3R: Training-free temporal-spatial adaptive persistent state for streaming 3d reconstruction, 2026. URL <https://arxiv.org/abs/2601.22615>.
- Dong Zhuo, Wenzhao Zheng, Jiahe Guo, Yuqi Wu, Jie Zhou, and Jiwen Lu. Streaming 4d visual geometry transformer, 2025. URL <https://arxiv.org/abs/2507.11539>.